

# O Que é Aprendizado de Máquina (I)

Teorema de aproximação universal: Uma rede com uma camada pode Codificar as melhores decisões para resolver um problema, porém isto demanda tempo e pode se tornar grande demais.

Otimização - Rede profunda, organizando os “neurônios” por camadas, possibilitando que um agrupamento de neurônios possa opinar sobre algo, mas não seja diretamente utilizado para responder outra, isto possibilita que hajam menor quantidade de respostas(Menor tempo) e por consequência possam aprender de maneira mais rápida.

Convolucionais - O neurônio que errou, acaba extraíndo o que levou ao erro tornando assim ele mais suscetível a não errar mais sobre isto, refinando suas decisões sobre o tema em questão. Isto possibilita até mesmo retornar uma resposta imediata, sem que tenha necessidade de acessar as outras camadas de neurônio, este tipo de rede, chamamos de convolucionais, das quais reconhecem os padrões mais importantes para resposta(Muito utilizado em identificação de rostos, fotos, jogos), é como se a cada padrão a pesquisa se tornasse mais e mais específica, gerando uma resposta mais precisa.

As redes neurais, possibilitam a identificação da fala(Assistentes como Alexa) de ideias(GPT, Copilot) mas também possibilita que programadores construam ideias específicas que impactem diretamente no cotidiano de muitas pessoas, como esta rede, que identifica a queda de um idoso, disparando assim uma resposta de queda a Tutor/responsável:

[https://www.linkedin.com/posts/bruno-de-sousa-donato\\_python-computervision-visaocomputacional-ugcPost-7138599159267266561-cFSG?utm\\_source=share&utm\\_medium=member\\_desktop](https://www.linkedin.com/posts/bruno-de-sousa-donato_python-computervision-visaocomputacional-ugcPost-7138599159267266561-cFSG?utm_source=share&utm_medium=member_desktop)

## Identificação de padrões

A identificação de padrões de imagem em seu core, não aparenta ser algo difícil, entender que um quadro é um quadro a primeiro momento é algo fácil e rápido, mas

que passa por uma série de indagações em nosso cérebro que prontamente respondemos e trazemos a resolução, mas que para uma rede neural, precisa não somente de várias linhas de código, mas de dias analisando o que é um quadro e o que não é.

Se observamos uma fotografia antiga em que não temos total certeza de que foi um pintor ou um fotografo que tirou, das quais já se encontram deterioradas pelo tempo, amareladas, um pouco sujas, com papel seco, ficamos na dúvida ao realizar resposta, precisando indagar morador da casa como foi feita. Uma rede neural, muitas vezes não foi programada para realizar essa pergunta e assume criterios mais generalistas para encontrar a resposta. Pode partir pelo fato de um quadro ter borda, mas fotografias também podem ter borda, pode partir pelo desenho dos rostos das pessoas que não estão tão bem definidos, mas as fotos de época também não tinham grande resolução/definição, pode utilizar ideia da cor para chegar a resposta, mas e se a pintura foi feita preta a branco?


Chegar a resposta não é algo fácil, por isto mesmo que é tão difícil desenvolver aplicações que possam dar sempre uma resposta absoluta. Um caso interessante é o do seguinte video que aborda a ideia de treino de uma rede neural em um jogo de corrida:

[https://www.youtube.com/watch?v=Dw3BZ6O\\_8LY](https://www.youtube.com/watch?v=Dw3BZ6O_8LY)

## Programação tradicional



Regras e dados, trazem uma resposta.



Porém invertendo isso, podemos fazer com que um algoritmo consiga identificar através das respostas dadas e dados deste jogo as regras do mesmo.

$x = -1, 0, 1, 2, 3, 4$

$y = -3, -1, 1, 3, 5, 7$

A relação entre as duas é algo relativamente simples,

sendo  $x$  a inclusão de  $+1$  e  $y$   $+2$  (exatamente como um estrutura de repetição em uma linguagem de programação

```
for (x=-1; x<100; x++) . . .  
for (y=-3; y<100; y+=2) . . .
```

Sendo também uma simples operação de:  $Y=2 * X -1$ .

São caminhos diferentes que geram respostas diferentes, enquanto estrutura de repetição me trás o retorno do que cada um é individualmente, o outro me trás a ideia do que é cada um.

```
Nova pasta > Machine learning > machine.py > ...
1 import tensorflow as tf
2 import numpy as np
3 from tensorflow import keras
4
5
6 #define modelo entre si
7 #unica camada com um unico neurônio
8 model = keras.Sequential([keras.layers.Dense(units=1, input_shape=[1])])
9 #perda e otimizador, fazendo suposição entre os números
10 #através da suposição irá identificar se suposição é boa ou ruim
11 #gerando uma nova suposição através da função de otimização
12 model.compile(optimizer='sgd', loss='mean_squared_error')
13 #matriz de X e Y
14 xs = np.array([-1.0,0.0,1.0,2.0,3.0,4.0])
15 ys = np.array([-3.0,-1.0,1.0,3.0,5.0,7.0])
16 #tente por 500 vezes esse processo
17 model.fit(xs,ys, epochs=500)

PROBLEMS OUTPUT TERMINAL
Epoch 490/500
1/1 [=====] - 0s 1ms/step - loss: 5.4146e-05
Epoch 491/500
1/1 [=====] - 0s 1ms/step - loss: 5.3834e-05
Epoch 492/500
1/1 [=====] - 0s 515us/step - loss: 5.1945e-05
Epoch 493/500
1/1 [=====] - 0s 1ms/step - loss: 5.0878e-05
Epoch 494/500
1/1 [=====] - 0s 2ms/step - loss: 4.9832e-05
Epoch 495/500
1/1 [=====] - 0s 1ms/step - loss: 4.8808e-05
Epoch 496/500
1/1 [=====] - 0s 1ms/step - loss: 4.7805e-05
Epoch 497/500
1/1 [=====] - 0s 2ms/step - loss: 4.6824e-05
Epoch 498/500
1/1 [=====] - 0s 667us/step - loss: 4.5863e-05
Epoch 499/500
1/1 [=====] - 0s 1ms/step - loss: 4.4920e-05
Epoch 500/500
1/1 [=====] - 0s 1ms/step - loss: 4.3997e-05
1/1 [=====] - 0s 61ms/step
[[18.980648]]
PS C:\Users\leofe\Documents\Nova pasta>
```

Ao gerar um algoritmo de machine learning por sua vez, pode averiguar que ao realizar 500 tentativas mirando na predição de 10, resposta me trouxe um valor aproximado de 18,98... :

$$x = -1, 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10$$

$$y = -3, -1, 1, 3, 5, 7, 9, 11, 13, 15, 17, 19$$

Sendo a predição o valor de x=10 e a predição um valor muito próximo a resposta real. Motivo de trazer deste modo é que aparenta ser uma linha reta de valores, mas ao adicionar a predição, existe uma imprecisão, mas que ainda gera um valor muito próximo ao devido.